

Clasificación del nivel de habilidad en partidas de ajedrez mediante redes neuronales usando el Chess Game Dataset (Lichess).

1. Descripción del problema

El objetivo de este proyecto es aplicar técnicas de aprendizaje automático para resolver un problema de clasificación multiclase. El sistema deberá predecir la categoría o nivel de los jugadores implicados en una partida de ajedrez (por ejemplo: Principiante, Intermedio o Avanzado) basándose exclusivamente en las estadísticas y características de desarrollo del juego. Desde pequeño he jugado al ajedrez llegando a tener un nivel considerablemente lo cual me permitirá realizar un análisis exploratorio con mayor rigor, interpretando correctamente el impacto de variables como el tipo de apertura o la duración antes de la rendición.

2. Conjunto de datos propuesto

Para el desarrollo del proyecto, se utilizará el conjunto de datos público "Chess Game Dataset" (autor: datasnaek), alojado en la plataforma Kaggle. Este dataset contiene registros de partidas reales jugadas en el servidor Lichess. Link: <https://www.kaggle.com/datasets/datasnaek/chess>

Dado que el archivo original (games.csv) consta de más de 20.000 registros, y con el fin de cumplir con el requisito de utilizar entre unos cientos y unos pocos miles de ejemplos, aplicaré un muestreo aleatorio (o un filtrado por un ritmo de juego específico) para aislar un subconjunto de aproximadamente 2.000 a 3.000 partidas. Esto garantizará un volumen manejable para entrenar los modelos eficientemente.

Las variables independientes (características) que se utilizarán, presentes de forma nativa en el dataset, son:

- `opening_eco` y `opening_ply`: El código de la apertura jugada y la cantidad de movimientos de la misma.
- `turns`: Duración total de la partida (cantidad de movimientos).
- `increment_code`: Ritmo de juego o control de tiempo empleado en la partida.
- `victory_status`: Cómo terminó la partida (rendición, jaque mate, fin de tiempo o tablas).

La variable objetivo (target) se derivará de las columnas `white_rating` y `black_rating` (el ELO de los jugadores). Estos valores numéricos continuos se agruparán y transformarán

en una única variable categórica discreta de tres clases representativas del "nivel general" de la partida.

3. Metodología y técnicas a aplicar

El desarrollo comenzará con un análisis exploratorio y un exhaustivo preprocesado de los datos. Será especialmente relevante la conversión de variables categóricas (como los códigos ECO de aperturas o el victory_status) a formatos numéricos adecuados para las matemáticas del modelo.

En la fase de modelado, se evaluarán diferentes algoritmos de clasificación multiclase. El núcleo del proyecto será la implementación y entrenamiento de redes neuronales desarrolladas desde cero haciendo uso exclusivo de la librería numpy. La validación del sistema se llevará a cabo dividiendo los datos en conjuntos de entrenamiento, validación y prueba, aplicando validación cruzada, buscando las mejores configuraciones de hiperparámetros y construyendo las curvas de entrenamiento/validación para diagnosticar posibles problemas de overfitting o underfitting.